


Datavalidering i Python med Pandera

En praktisk fördjupning med orderdata



Analysens kvalitet beror på kvaliteten på datan

Fält	Problem i datan
quantity	-1 / "two" ✗
unit_price	-349.50 ✗
discount	1.25 ✗
order_date	"not-a-date" ✗
product_category	"Toys" ✗
customer_id	saknat värde ✗


Vad kontrolleras i projektet?

- Obligatoriska kolumner
- Saknade värden
- Datum
- Numeriska värden
- Intervall
- Tillåtna kategorier
- Booleska värden

Utan validering kan felaktiga värden följa med vidare till analysen.

Pandera i dataflödet

Valideringen sker innan analysen



DataFrameSchema

Definierar reglerna för datan.



Column

Beskriver regler för en specifik kolumn.



Check

Kontrollerar ett villkor, t.ex. ett tillåtet intervall.



lazy=True

Samlar flera valideringsfel istället för att stoppa vid det första.

```
"discount": pa.Column(
    float,
    nullable=False,
    checks=pa.Check.between(0, 1)
)
```

Regel: discount måste vara mellan 0 och 1.

Vad händer med datan?

Valid data analyseras — invalid data stoppas

✓ VALID DATA

valid_orders.csv

Validation successful

20

orders

11 960,47

total sales

598,02

avg order

→ Analysis executed

✗ INVALID DATA

invalid_orders.csv

Validation failed

Exempel på upptäckta fel:

- quantity = -1
- quantity = "two"
- unit_price = -349.50
- discount = 1.25
- order_date = "not-a-date"
- product_category = "Toys"

→ Analysis not executed

JÄMFÖRELSE

Pandera vs. manuell validering i Pandas

Pandera ersätter inte Pandas — det strukturerar datavalideringen

	Pandas	Pandera
Regler	Manuella villkor	Schema
Struktur	Spridda kontroller	Samlade regler
Felrapportering	Egna felmeddelanden	failure_cases
Flexibilitet	Mycket hög	Mer strukturerad
Passar bäst för	Specifika/enkla kontroller	Många återkommande regler

Pandas

```
invalid = orders["discount"].isna() | \
    orders["discount"].gt(1)
```

Pandera

```
pa.Check.between(0, 1)
```

Pandas ger flexibilitet. Pandera ger en tydlig struktur för valideringsregler.

Manuell Pandas-validering ger stor frihet, särskilt vid specifik logik. Pandera tillför framför allt ett strukturerat schema och en mer samlad hantering av regler och fel.

Vad lärde jag mig?

Datavalidering är ett eget steg i ett robust dataflöde

Jag lärde mig

- ✓ Bygga ett DataFrameSchema
- ✓ Definiera Column och Check
- ✓ Hantera flera valideringsfel
- ✓ Stoppa analys vid ogiltig data
- ✓ Skriva tester för valideringen

Viktiga begränsningar

- Liten prototyp
- CSV som datakälla
- Begränsat antal valideringsregler
- Inte en komplett produktionslösning
- Vissa affärsregler kan kräva separat logik

Data



Validation



Analysis



Reliable results

Data Scientist / Data Analyst

En viktig lärdom är att datavalidering inte handlar om att göra all data "perfekt" — utan om att tydligt definiera vilka dataregler som krävs för att nästa steg ska vara tillförlitligt.